# 10　熵、统计距离与散度

本节讨论离散随机变量。沿用 $p_X(x)=\Pr[X=x]$、$p_{X,Y}(x,y)=\Pr[X=x,Y=y]$ 和 $p_{X\mid Y}(x\mid y)$ 的记号。一般分布记作 $P,Q$；$H(P)$ 和 $H(X)$ 分别表示分布及服从该分布的随机变量的熵。除非特别说明，$\log=\log_2$，并约定 $0\log(1/0)=0$。涉及熵的相减及取等条件时，假设有关熵有限，以避免 $\infty-\infty$。

## 10.1　熵及其基本性质

**定义 10.1（熵（Entropy））.** 若 $X\sim p_X$，定义

$$H(X)=H(p_X)=\sum_{x}p_X(x)\log\frac{1}{p_X(x)}=\mathbb{E}\left[\log\frac{1}{p_X(X)}\right].$$

求和中的零概率项按 0 处理。

对数的底决定熵的单位：

| 对数 | $\log_2$ | $\ln$ | $\log_{256}$ |
|---|---|---|---|
| 单位 | bit | nat | byte |

全文使用同一个底数；在求导时，$\frac{\mathrm{d}}{\mathrm{d}t}\log t=(\log e)/t$，其中 $\log e=1/\ln 2$。

**命题 10.2（非负性与双射不变性）.** 有 $H(X)\ge 0$，且 $H(X)=0$ 当且仅当 $X$ 以概率 1 为某个常数。若 $f$ 在 $X$ 的取值集合上是双射，则 $H(f(X))=H(X)$。

*证明.* 每个 $p_X(x)\log(1/p_X(x))$ 都非负；所有正概率项均为零时，唯一的正概率必须为 1。双射只重新标记这些概率，不改变求和结果。 □

**命题 10.3（有限支持集上的熵上界）.** 记 $\operatorname{supp}(X)=\{x:p_X(x)>0\}$。若支持集有限，则

$$H(X)\le\log\bigl|\operatorname{supp}(X)\bigr|=H_{\max}(X).$$

*证明.* 利用 $\log$ 的凹性及 Jensen 不等式，

$$\begin{aligned}H(X)&=\sum_{x\in\operatorname{supp}(X)}p_X(x)\log\frac{1}{p_X(x)}\\&\le\log\left(\sum_{x\in\operatorname{supp}(X)}p_X(x)\frac{1}{p_X(x)}\right)=\log\bigl|\operatorname{supp}(X)\bigr|.\end{aligned}$$

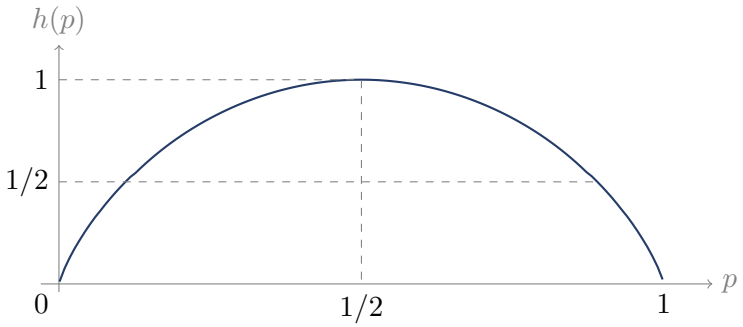
□

**例 10.4（二元熵函数）.** 若 $X\sim\mathrm{Bern}(p)$，定义

$$h(p)=H(X)=p\log\frac{1}{p}+(1-p)\log\frac{1}{1-p},\qquad 0\le p\le 1.$$

它关于 $p=1/2$ 对称，$h(0)=h(1)=0$，$h(1/2)=1$ bit。板书图中的半比特水平线约对

应 $p = 0.11$ 和 $p = 0.89$。




## 10.2 联合熵、条件熵与链式法则

**定义 10.5 (联合熵与条件熵).** 定义

$$H(X,Y) = \sum_{x,y} p_{X,Y}(x,y) \log \frac{1}{p_{X,Y}(x,y)}.$$

对 $p_Y(y) > 0$，记

$$H(X \mid Y = y) = \sum_{x} p_{X|Y}(x \mid y) \log \frac{1}{p_{X|Y}(x \mid y)}.$$

条件熵是这些条件分布的熵的加权平均：

$$H(X \mid Y) = \sum_{y:\, p_Y(y)>0} p_Y(y) H(X \mid Y = y).$$

展开定义并用 $p_Y(y)p_{X|Y}(x \mid y) = p_{X,Y}(x,y)$，有

$$\begin{aligned} H(X \mid Y) &= \sum_{y} p_Y(y) \sum_{x} p_{X|Y}(x \mid y) \log \frac{1}{p_{X|Y}(x \mid y)} \\ &= \sum_{x,y} p_{X,Y}(x,y) \log \frac{1}{p_{X|Y}(x \mid y)} \\ &= \mathbb{E}_{(X,Y)\sim p_{X,Y}} \left[ \log \frac{1}{p_{X|Y}(X \mid Y)} \right]. \end{aligned}$$

这里求和仅涉及正联合概率的点；零概率条件事件不参与计算。

**命题 10.6 (条件熵的非负性与零值条件).** $H(X \mid Y) \geq 0$，且 $H(X \mid Y) = 0$ 当且仅当对每个 $p_Y(y) > 0$ 的 $y$，给定 $Y = y$ 后 $X$ 以概率 1 为常数。等价地，存在函数 $g$，使 $X = g(Y)$ 以概率 1 成立。

*证明.* 条件熵是各个非负熵 $H(X \mid Y = y)$ 的加权平均。平均值为零等价于每个具有正权重的条件熵都为零，再用熵的零值条件即可。 □

**命题 10.7 (熵的链式法则).**

$$H(X,Y) = H(Y) + H(X \mid Y) = H(X) + H(Y \mid X).$$

证明. 在正联合概率的点上，

$$\log \frac{1}{p_{X,Y}(x,y)} = \log \frac{1}{p_Y(y)} + \log \frac{1}{p_{X|Y}(x \mid y)}.$$

两边对联合分布取期望，得到第一个等式；交换 $X, Y$ 得到第二个等式。 □

## 10.3 熵的凹性与条件化的作用

**命题 10.8 (熵对分布的凹性).** 设 $P_0, P_1$ 是同一离散集合上的分布，$0 \le \lambda \le 1$，则

$$H\big(\lambda P_1 + (1-\lambda)P_0\big) \ge \lambda H(P_1) + (1-\lambda)H(P_0).$$

证明. 端点 $\lambda = 0, 1$ 时显然成立。以下设 $0 < \lambda < 1$。取 $Z \sim \mathrm{Bern}(\lambda)$，给定 $Z = i$ 后按分布 $P_i$ 抽取 $Y$。这也可写为：取 $X_i \sim P_i$，使 $Z$ 独立于 $(X_0, X_1)$，并令

$$Y = X_Z = \begin{cases} X_0, & Z = 0, \\ X_1, & Z = 1. \end{cases}$$

则 $Y$ 的分布为 $P = \lambda P_1 + (1-\lambda)P_0$。由链式法则，

$$\begin{aligned} H(Y,Z) &= H(Z) + H(Y \mid Z) \\ &= h(\lambda) + \lambda H(P_1) + (1-\lambda)H(P_0), \\ H(Y,Z) &= H(Y) + H(Z \mid Y). \end{aligned}$$

设 $f(y) = \Pr[Z = 1 \mid Y = y]$，则

$$f(y) = \frac{\lambda P_1(y)}{\lambda P_1(y) + (1-\lambda)P_0(y)} \quad (P(y) > 0),$$

并且

$$\mathbb{E}[f(Y)] = \Pr[Z = 1] = \lambda, \qquad H(Z \mid Y) = \mathbb{E}[h(f(Y))].$$

二元熵 $h$ 是凹函数：在 $0 < t < 1$ 上有 $h''(t) = -(\log e)(1/t + 1/(1-t)) < 0$。由 Jensen 不等式，

$$H(Z \mid Y) = \mathbb{E}[h(f(Y))] \le h(\mathbb{E}[f(Y)]) = h(\lambda).$$

比较 $H(Y,Z)$ 的两种表达，即得结论。 □

上面的 $f(y)$ 一般不恒等于 $\lambda$；它是后验概率。当 $P_0 = P_1$ 时，在 $P(y) > 0$ 的点上有 $f(y) = \lambda$。

**命题 10.9 (条件化不增加平均熵).**

$$H(X \mid Y) \le H(X).$$

*证明.* 边缘分布是条件分布的混合：

$$p_X = \sum_{y:\, p_Y(y)>0} p_Y(y)\, p_{X\mid Y=y}.$$

由熵的凹性（同样适用于上述加权混合），

$$H(X) = H(p_X) \ge \sum_y p_Y(y) H(p_{X\mid Y=y}) = H(X \mid Y).$$

□

**命题 10.10 (联合熵的上界与取等条件).**

$$H(X,Y) = H(X) + H(Y \mid X) \le H(X) + H(Y),$$

等号成立当且仅当 $X, Y$ 独立。

*证明.* 不等式由链式法则与条件化不增加平均熵得到。熵对分布严格凹，所以混合分布的熵等于条件熵平均值，当且仅当所有正权重的条件分布相同。这正是 $p_{Y\mid X=x} = p_Y$ 对所有 $p_X(x) > 0$ 的 $x$ 成立，即 $X, Y$ 独立。 □

**命题 10.11 (完整链式法则与相互独立).** 对 $X_1, \dots, X_n$，

$$\begin{aligned} H(X_1, \dots, X_n) &= H(X_1) + \sum_{i=2}^{n} H(X_i \mid X_1, \dots, X_{i-1}) \\ &\le \sum_{i=1}^{n} H(X_i). \end{aligned}$$

等号成立当且仅当 $X_1, \dots, X_n$ 相互独立，即

$$p_{X_1,\dots,X_n}(x_1, \dots, x_n) = \prod_{i=1}^{n} p_{X_i}(x_i).$$

等价地，对每个 $i$，$X_i$ 与其余变量组成的向量 $(X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_n)$ 独立。

*证明.* 反复使用二元链式法则，再对每个条件熵应用上界。等号要求每一步均取等，因而各个条件分布依次等于相应边缘分布，得到乘积分解；反之直接代入即可。 □

## 10.4 统计距离：全变差距离与耦合

**定义 10.12（全变差距离（Total Variation Distance））.** 对同一离散集合上的分布 $P, Q$，定义

$$\Delta_{\mathrm{TV}}(P, Q) = \frac{1}{2}\|P - Q\|_1 = \frac{1}{2}\sum_x |P(x) - Q(x)|.$$

板书中的 statistical distance 指这里的全变差距离。

因为 $\sum_x (P(x) - Q(x)) = 0$，正差之和等于负差绝对值之和，故

$$\begin{aligned}\Delta_{\mathrm{TV}}(P, Q) &= \sum_x \max\{0, P(x) - Q(x)\} \\ &= 1 - \sum_x \min\{P(x), Q(x)\}.\end{aligned}$$

**命题 10.13（全变差距离的耦合解释）.** 在所有边缘分布满足 $X \sim P$、$Y \sim Q$ 的联合分布中，

$$\min \Pr[X \neq Y] = \Delta_{\mathrm{TV}}(P, Q).$$

这样的联合分布称为 $P, Q$ 的耦合；这里不要求 $X, Y$ 独立。

证明. 任意耦合都满足

$$\Pr[X = Y = v] \le \min\{P(v), Q(v)\}.$$

所以

$$\Pr[X = Y] \le \sum_v \min\{P(v), Q(v)\} = 1 - \Delta_{\mathrm{TV}}(P, Q).$$

为使等号达到，记 $a(v) = \min\{P(v), Q(v)\}$，$\delta = 1 - \sum_v a(v)$。若 $\delta = 0$，取 $X = Y \sim P = Q$。若 $\delta > 0$，定义联合分布

$$R(x, y) = a(x)\mathbf{1}_{\{x=y\}} + \frac{(P(x) - a(x))(Q(y) - a(y))}{\delta}.$$

其边缘分布分别为 $P, Q$，而 $(P(v) - a(v))(Q(v) - a(v)) = 0$，故 $R(v, v) = a(v)$。于是 $\Pr[X \neq Y] = \delta = \Delta_{\mathrm{TV}}(P, Q)$。 □

## 10.5 KL 散度及其非负性

**定义 10.14（KL 散度（Kullback–Leibler Divergence））.** 对分布 $P, Q$，定义

$$D_{\mathrm{KL}}(P\|Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)} = \mathbb{E}_{X \sim P}\left[\log \frac{P(X)}{Q(X)}\right].$$

简记为 $D(P\|Q)$。若 $\mathrm{supp}(P) \not\subseteq \mathrm{supp}(Q)$，则 $D(P\|Q) = +\infty$。零概率项按 $0 \log(0/q) = 0$（包括 $q = 0$）处理；正概率除以零的项为 $+\infty$。

**命题 10.15 (KL 散度的非负性).**

$$D(P\|Q)\ge 0,\qquad D(P\|Q)=0\iff P=Q.$$

特别地，$D(P\|P)=0$。

证明. 支持集条件不满足时，散度为 $+\infty$，结论成立。否则，令 $\varphi(t)=t\log t$ 并连续定义 $\varphi(0)=0$。由 $\varphi$ 的严格凸性及 Jensen 不等式，

$$\begin{aligned}D(P\|Q)&=\sum_{x:\,Q(x)>0}Q(x)\varphi\left(\frac{P(x)}{Q(x)}\right)\\&\ge\varphi\left(\sum_{x:\,Q(x)>0}Q(x)\frac{P(x)}{Q(x)}\right)=\varphi(1)=0.\end{aligned}$$

等号成立当且仅当 $P(x)/Q(x)$ 在 $Q(x)>0$ 的点上恒定；归一化使这个常数为 $1$，即 $P=Q$。 □

## 10.6 Bernoulli 散度及其二次下界

**定义 10.16 (Bernoulli 散度).** 记

$$d(p\|q)=D\big(\mathrm{Bern}(p)\|\,\mathrm{Bern}(q)\big)=p\log\frac{p}{q}+(1-p)\log\frac{1-p}{1-q}.$$

端点按前述零概率与无穷大的约定处理。

固定 $0<q<1$ 时，$p\mapsto d(p\|q)$ 在 $p=q$ 处达到最小值 $0$，端点值为

$$d(0\|q)=\log\frac{1}{1-q},\qquad d(1\|q)=\log\frac{1}{q}.$$

这对应板书中以 $p=q$ 为最低点的凸曲线。

**命题 10.17 (Bernoulli 散度的二次下界).** 对 $p,q\in[0,1]$，有

$$d(p\|q)\ge 2(\log e)(p-q)^2.$$

证明. 先固定 $0<q<1$，在 $0<p<1$ 上求导：

$$\begin{aligned}\frac{\partial}{\partial p}d(p\|q)&=\log\frac{p}{q}+\log e-\log\frac{1-p}{1-q}-\log e\\&=\log\frac{p}{q}-\log\frac{1-p}{1-q},\\\frac{\partial^2}{\partial p^2}d(p\|q)&=(\log e)\left(\frac{1}{p}+\frac{1}{1-p}\right)=\frac{\log e}{p(1-p)}\ge 4\log e.\end{aligned}$$

利用 $d(q\|q)=0$ 和 $\frac{\partial}{\partial p}d(p\|q)\Big|_{p=q}=0$，Taylor 公式给出

$$d(p\|q)\ge\frac{1}{2}(4\log e)(p-q)^2.$$

$p=0,1$ 时由连续性得到结论；$q=0,1$ 时，或者 $p=q$ 散度为零，或者散度为 $+\infty$。 □

注 10.18 (对数底数与常数). 若使用自然对数，$\log e=1$，上面的二次下界为 $d(p\|q)\ge 2(p-q)^2$。本节用 $\log_2$，因此保留 $\log_2 e$；这也是板书最后补上的换底因子。

## 10.7 条件散度与散度链式法则

**定义 10.19 (条件分布诱导的联合分布).** 给定边缘分布 $P_X$ 和条件分布 $P_{Y|X}$，记

$$(P_{Y|X}P_X)(x,y)=P_X(x)P_{Y|X}(y\mid x).$$

同理，$Q_{Y|X}P_X$ 表示保持相同边缘 $P_X$，但换用条件分布 $Q_{Y|X}$ 所得的联合分布。

**定义 10.20 (条件 KL 散度).** 定义

$$\begin{aligned}
&D(P_{Y|X}\|Q_{Y|X}\mid P_X)\\
&\quad=\sum_{x:\,P_X(x)>0}P_X(x)D\big(P_{Y|X=x}\|Q_{Y|X=x}\big)\\
&\quad=\sum_{x,y}P_X(x)P_{Y|X}(y\mid x)\log\frac{P_{Y|X}(y\mid x)}{Q_{Y|X}(y\mid x)}\\
&\quad=\mathbb{E}_{(X,Y)\sim P_{Y|X}P_X}\left[\log\frac{P_{Y|X}(Y\mid X)}{Q_{Y|X}(Y\mid X)}\right].
\end{aligned}$$

这里外层按 $P_X$ 加权，期望按 $P_{Y|X}P_X$ 取。

**命题 10.21 (相同边缘时的联合散度).**

$$D(P_{Y|X}\|Q_{Y|X}\mid P_X)=D(P_{Y|X}P_X\|Q_{Y|X}P_X).$$

证明. 在 $P_X(x)>0$ 的点上约去相同边缘概率：

$$\begin{aligned}
&D(P_{Y|X}P_X\|Q_{Y|X}P_X)\\
&\quad=\mathbb{E}_{(X,Y)\sim P_{Y|X}P_X}\left[\log\frac{P_X(X)P_{Y|X}(Y\mid X)}{P_X(X)Q_{Y|X}(Y\mid X)}\right]\\
&\quad=\mathbb{E}_{(X,Y)\sim P_{Y|X}P_X}\left[\log\frac{P_{Y|X}(Y\mid X)}{Q_{Y|X}(Y\mid X)}\right].
\end{aligned}$$

□

**命题 10.22 (KL 散度的链式法则).** 设 $P_{X,Y}=P_{Y|X}P_X$，$Q_{X,Y}=Q_{Y|X}Q_X$，则

$$\begin{aligned}
D(P_{X,Y}\|Q_{X,Y})&=D(P_X\|Q_X)\\
&\quad+D(P_{Y|X}\|Q_{Y|X}\mid P_X).
\end{aligned}$$

证明. 先在 $D(P_{X,Y}\|Q_{X,Y})<\infty$ 的情形下展开，所有期望均按 $P_{X,Y}$ 取：

$$\begin{aligned} D(P_{X,Y}\|Q_{X,Y}) &= \mathbb{E}\left[\log\frac{P_{X,Y}(X,Y)}{Q_{X,Y}(X,Y)}\right] \\ &= \mathbb{E}\left[\log\frac{P_X(X)}{Q_X(X)}\right] \\ &\quad + \mathbb{E}\left[\log\frac{P_{Y|X}(Y\mid X)}{Q_{Y|X}(Y\mid X)}\right] \\ &= D(P_X\|Q_X) + D(P_{Y|X}\|Q_{Y|X}\mid P_X). \end{aligned}$$

一般情形下，等式按非负扩展实数解释；若 $Q_X(x)=0<P_X(x)$，第一项已为 $+\infty$，可在这些点任取 $Q_{Y|X=x}$ 的版本而不影响等式。 □